

IEEE Access — Pacote ÚNICO Reviewer 3

TOMWare.M · Access-2026-38745

Minor points → reuse R1/R2 evidence → Overleaf + Response Letter

Dados: AntiDebug matched; corpus fixed-1 9/31≈29% re-exec; SkewMask N=30 com IQR+IC95%; tabela related systems.

Como usar: (1) mapa R3; (2) auditoria 3 eixos; (3) cole Seção 7 no Overleaf; (4) Response Seção 8; (5) language checklist. VM nova não é necessária — o gap é colar no manuscrito.

0. Mapa dos pontos do Reviewer 3

Item	Evidência	Manuscrito	Ação
1 AntiDebug matched	ATENDIDO	PARCIAL	Colar 7.1 + purge unvalidated
2 Re-exec ~29% / bias	ATENDIDO*	PARCIAL	Colar 7.2 (9/31=29.0%)
3 IC / descritivo	ATENDIDO	PARCIAL	Colar 7.3 IQR+IC95%
4 Tabela related	ATENDIDO	PARCIAL	Inserir tab:related-r3
5 Language / formatting	n/a	NÃO	Passada editorial Overleaf

* 9/31 = 29.0% ≈ “29%” citado pelo revisor (falha na 1ª tentativa no protocolo antigo com reexecução). Critério ChatGPT: pacote FEITO ≠ manuscript ATENDIDO.

0.1 Auditoria rigorosa (3 eixos) — veredito

Critério do share ChatGPT Reviewer 3: classificar ATENDIDO / PARCIALMENTE / NÃO verificando (1) evidência experimental, (2) texto sem extrapolação, (3) alteração efetiva no manuscrito. O share define o rigor mas não fecha o veredicto; abaixo o fechamento operacional.

Ponto	Global	Notas
R3-1 AntiDebug	PARCIAL	Evidência matched OK; bloqueio = purge unvalidated + colar 7.1
R3-2 Bias 29%	PARCIAL	Números + mitigação N=30 OK; colar 7.2 no artigo
R3-3 IC/descritivo	PARCIAL	IQR+IC95% oracle OK; corpus descriptive; colar 7.3
R3-4 Related table	PARCIAL	Tabela arquitetural OK; sem H2H/superioridade; inserir tab
R3-5 Language	NÃO	Só fecha após passada editorial no Overleaf

Veredito: evidências R3 ATENDIDAS; integração manuscrito ainda PARCIAL. Detalhe em `overleaf_pack_R3_COMPLETO/AUDITORIA_R3_RIGOROSA.md`.

1. AntiDebug matched (R3-1)

Pedido: repetir com -gdb baseline vs -gdb -dd, ou classificar o módulo como unvalidated em todo o manuscrito.

Resposta: já validado matched (R1/R2). Baseline -gdb -q; treatment -gdb-dd -q; 3 reps + controle Pin-only. Não classificar como unvalidated. Tipo do revisor -gdb = -gdb.




Fig. R3-1 — Matched AntiDebug (reuse R1/R2).

2. Taxa de reexecução ~29% e selection bias (R3-2)

Pedido: clarificar implicações da taxa de reexecução do timing-oracle (~29%) e o possível bias de seleção ao reter runs que satisfazem o limiar.

Números: leitura fixed-1 dos reports do corpus: 22/31 passam na 1ª tentativa; 9/31 (29.0%) falham na 1ª e, no protocolo antigo, usavam reexecução.

Implicação / bias: se só se publicam trials que eventualmente passam o limiar, a probabilidade aparente de sucesso sobe e as estatísticas de tempo tendem a runs “fáceis”/threshold-satisfying. Isso enfraquece claims causais sobre o módulo.

Mitigação neste revisão: (1) reportar first-attempt vs reexecução; (2) corpus aggregates = descriptive; (3) oracle SkewMask redesenhado com fixed-N=30 retendo todas as execuções (IQR + IC95%).

3. Incerteza / resultados descriptivos (R3-3)

Pedido: adicionar medidas de incerteza (ex.: IC) onde viável, ou enfatizar que os resultados de performance são apenas descritivos.

Oracle N=30 (todas retidas): B above 23/30, median=3213.49, IQR=[3062.36, 3511.81], IC95%=[3140.16, 3432.05]. C OK 30/30, median=2114.34, IQR=[2109.25, 2122.07], IC95%=[2112.96, 2119.14].

Corpus PE medians: permanecem descriptive only (sem testes de significância). Não extrapolamos IC do oracle N=30 para cada PE do corpus.



Fig. R3-3 — SkewMask distributions / fixed-N (reuse).

4. Tabela concisa vs sistemas próximos (R3-4)

Pedido: comparar brevemente TOMWare.M com os sistemas mais próximos em uma tabela.

Dimensão	Arancino	COBAI	Peekaboo	TOMWare.M
Papel	Camada defensiva Pin	Ferramenta DBI	Análise / evasão DBI	Pintool modular Win x64
Ativação	Integrada	Framework	Framework	Knobs -dd..-do / -da
Eval. aqui	Não re-run	Não re-run	Não re-run	Oracles + corpus probe
H2H empírico	Não	Não	Não	—

Redação: In our comparison, TOMWare.M combines... (evita “uniquely enables” absoluto). Sem benchmark compartilhado.

5. Language & formatting (R3-5)

Pedido: revisão final de idioma/formatação (typos e espaçamento).

- 1. Unificar hífens: anti-instrumentation / AntiDebug / Pin-only.
- 2. Mapear typo do revisor: -gbd → -gdb em texto e legendas.
- 3. Espaços consistentes em knobs: -gdb -dd; -go -do -q.
- 4. Captions: pontuação final; unidades com espaço não-quebrável se necessário.
- 5. Tabelas: alinhamento SHA / monoespaçado; evitar wrap estranho em Overleaf.
- 6. Abstract/Results: AntiDebug = matched (não “inconclusive”).
- 7. Discussion: parágrafo 29% + bias + mitigação N=30.

7. TEXTOS OVERLEAF (colar)

7.1 AntiDebug matched (R3-1)

The AntiDebug countermeasure was functionally validated under matched conditions (-gdb -q baseline vs -gdb -dd -q treatment; reviewer typo -gbd = -gdb), with a Pin-only control. We therefore do not classify this module as unvalidated.

7.2 Re-execution / selection bias (R3-2)

Earlier corpus timing reports allowed additional attempts after a failed first run. Under a fixed-1-attempt reading, 22/31 samples completed on the first attempt, whereas 9/31 (29.0%) required at least one re-execution. Retaining only eventually successful trials can inflate apparent success and bias timing summaries toward threshold-satisfying runs. We report the first-attempt recount explicitly, treat corpus aggregates as descriptive, and redesign the SkewMask oracle to a fixed-N protocol that retains every run.

7.3 Uncertainty (R3-3)

Under fixed-N=30 with all runs retained, TestOverhead exceeded the calibrated limit (3000) in 23/30 baseline runs (median 3213.49, IQR [3062.36, 3511.81], 95% bootstrap CI [3140.16, 3432.05]) and in 0/30 treatment runs (OK 30/30; median 2114.34, IQR [2109.25, 2122.07], 95% CI [2112.96, 2119.14]). Corpus PE-level medians remain descriptive summaries without significance tests.

7.4 Related systems (R3-4)

We include a concise architectural comparison to Arancino, COBAI, and Peekaboo (Table tab:related-r3). We did not perform shared-workload empirical benchmarks against those systems. In our comparison, TOMWare.M combines selective module activation with matched oracle validation and an auditable compatibility-probe protocol under Intel Pin on Windows x64.

8. Response to Reviewer 3

R3-1 AntiDebug matched

- a) Concern: matched -gdb vs -gdb -dd, or classify unvalidated.
- b) Response: Completed matched validation (baseline -gdb -q; treatment -gdb -dd -q; Pin-only control). Module is not classified as unvalidated.
- c) Action: Figure + Abstract/Results (typo -gbd = -gdb).

R3-2 Re-execution / bias

- a) Concern: ~29% re-execution and selection bias.
- b) Response: Fixed-1 recount 9/31 (29.0%) needed re-exec under the old protocol; we discuss bias and mitigate via first-attempt reporting + fixed-N oracle retaining all runs.
- c) Action: Discussion paragraph + Response Letter.

R3-3 Uncertainty / descriptive

- a) Concern: CIs or emphasize descriptive-only performance.
- b) Response: Oracle N=30 reports IQR + 95% bootstrap CI; corpus medians remain descriptive (no significance tests).
- c) Action: Results stats wording.

R3-4 Related systems table

- a) Concern: concise comparison table with closest systems.
- b) Response: Architectural table vs Arancino/COBAL/Peekaboo; no invented empirical superiority; wording 'In our comparison, TOMWare.M combines...'.
c) Action: Table tab:related-r3.

R3-5 Language / formatting

- a) Concern: typos and spacing inconsistencies.
- b) Response: Editorial checklist applied in the revised Overleaf (knobs, hyphenation, captions, spacing). Not claimed done until manuscript paste.
- c) Action: Overleaf polish checklist (Section 5) + AUDITORIA_R3_RIGOROSA.md.

9. Arquivos

PDF: TOMWareM_Revisor3_COMPLETO_Overleaf.pdf

Pack: overleaf_pack_R3_COMPLETO/

Audit: AUDITORIA_R3_RIGOROSA.md (critério ChatGPT 3 eixos)

Reuse figs: fig_antidebug_matched.png, fig_skewmask_N30.png

Fonte stats: evidencias_VM_R2/ANALYSIS_skewmask_N30.json + r2_analytics/